

Sistem za preporuke filmova zasnovan na analizi sadržaja i semantičkoj sličnosti

Definicija problema/cilja projekta

Cilj projekta je razvoj sistema za preporuku filmova koji korisniku, na osnovu unetog naslova, predlaže filmove sa najvećim stepenom sličnosti. Projekat rešava problem efikasnog pronalaženja srodnog sadržaja u velikim bazama podataka i unapređuje korisničko iskustvo kroz funkcionalnosti kao što su pretraga, filtriranje, sortiranje i prikaz detaljnih informacija o filmovima.

- **Ulaz u sistem:** Naslov filma koji korisnik unosi.
- **Izlaz iz sistema:** Lista filmova sa najvećom semantičkom i sadržajnom sličnosti sa unetim naslovom, uz dodatne mogućnosti navigacije i pretrage.

Motivacija problema rešavanog u projektu

U eri masovne digitalne produkcije, korisnici su preplavljeni velikim izborom filmova, što dovodi do problema poznatog kao *overload of choice*. Sistemi za preporuke imaju ključnu ulogu u olakšavanju procesa pronalaženja relevantnog sadržaja. Razvoj sistema za preporuku filmova zasnovanog na analizi sadržaja i semantičkoj sličnosti omogućava korisnicima da brzo i precizno otkriju filmove koji odgovaraju njihovim interesovanjima, bez oslanjanja na istoriju korisničkih interakcija, što je naročito značajno u situacijama "hladnog starta" (novi korisnici ili novi filmovi).

Relevantna literatura

1. The Movie Recommendation System using Content Based Filtering with TF-IDF-Vectorization and Levenshtein Distance

- **Zadatak rada:** Cilj ovog rada je bio da razvije sistem za preporuke filmova koji se isključivo zasniva na analizi sadržaja, bez korišćenja podataka o interakciji korisnika. Fokus je stavljen na rešavanje problema "cold start", gde novi korisnici ili novi filmovi nemaju istoriju interakcije.
- **Metodologija:** Rad koristi TF-IDF (Term Frequency-Inverse Document Frequency) za vektorizaciju teksta, kao što su opisi i naslovi filmova. Za pronalaženje sličnih filmova koristi se kosinusna sličnost, a kao dodatna mera za poređenje naslova koristi se i Levenshteinova distanca.
- **Skup podataka:** Istraživanje je sprovedeno na skupu podataka koji sadrži naslove filmova, žanrove i opise. Rad eksplicitno navodi da se oslanja isključivo na attribute filma.
- **Evaluacija rešenja:** Evaluacija je sprovedena merenjem preciznosti (precision) i odziva (recall), kao i kvalitativnom analizom rezultata. Autori su uporedili performanse svog sistema sa jednostavnim, ne-personalizovanim preporukama.

- Najvažniji rezultati: Istraživanje je pokazalo da je sistem zasnovan na sadržaju izuzetno efikasan u rešavanju problema hladnog starta i da može da generiše relevantne preporuke sa značajnom tačnošću. Posebno je naglašeno da TF-IDF, u kombinaciji sa kosinusnom sličnošću, daje izuzetne rezultate u domenu preporuka.
- Šta nedostaje: Autori su koristili relativno jednostavne metode za vektorizaciju teksta (TF-IDF). U radu se ne istražuje primena naprednijih tehnika kao što je Word2Vec, koja bi mogla da uhvati semantičke odnose reči i dodatno poboljša preporuke. Takođe, nisu razmatrane metrike kao što su diverzitet ili Silueta skor, koje bi obogatile evaluaciju.
- Referenca:
https://www.researchgate.net/publication/360575583_The_Movie_Recommendation_System_using_Content_Based_Filtering_with_TF-IDF-Vectorization_and_Levenshtein_Distance

2. Step By Step Content-Based Recommendation System

- Zadatak rada: Cilj ovog rada bio je da se predstavi detaljan, korak-po-korak pristup implementaciji sistema za preporuku filmova zasnovanog na sadržaju. Poseban naglasak je stavljen na poređenje različitih tehnika vektorizacije teksta, uključujući Word2Vec.
- Metodologija: Rad je demonstrirao kako se kreira *feature matrix* na osnovu atributa filma (žanr, tagovi, naslov, opis). Korišćene su različite tehnike za vektorizaciju: Bag-of-Words, TF-IDF i Word2Vec. Sličnost je izračunata koristeći kosinusnu metriku. Rad ne uzima u obzir preferencije korisnika, već preporučuje filmove isključivo na osnovu sličnosti između samih filmova.
- Skup podataka: Projekat je koristio standardni IMDb movie dataset, koji se često koristi u istraživanju sistema za preporuke zasnovanih na sadržaju.
- Evaluacija rešenja: Evaluacija je bila fokusirana na demonstraciju rezultata, a ne na rigorozne numeričke mere. Korišćene su vizualizacije i primeri preporuka za ilustraciju uspešnosti sistema.
- Najvažniji rezultati: Zaključeno je da Word2Vec nadmašuje Bag-of-Words i TF-IDF jer bolje razume semantički kontekst reči, što rezultira boljim i relevantnijim preporukama.
- Šta nedostaje: Iako je Word2Vec obrađen, rad se ne bavi integracijom numeričkih atributa (poput ocena, popularnosti). Takođe, nisu korišćene sofisticirane metode evaluacije kao što su Silueta skor ili diverzitet, koje bi mogle da daju dublji uvid u kvalitet rešenja.
- Referenca:
<https://medium.com/@prateekgaurav/step-by-step-content-based-recommendation-system-823bbfd0541c>

3. Evaluation Metrics for Recommender Systems: A Comprehensive Analysis

- Zadatak rada: Cilj ovog preglednog rada je pružanje sveobuhvatne analize i kategorizacije metrika za evaluaciju sistema preporuka. Poseban naglasak je na metrikama koje mere ne samo preciznost, već i kvalitet preporuka sa aspekta diverziteta i novine.

- Metodologija: Rad analizira i sumira nalaze iz velikog broja istraživačkih studija. Autori definišu različite kategorije metrika, uključujući one zasnovane na tačnosti (accuracy), rangu (ranking), i kvalitetu preporuke (diversity, novelty). Objašnjavaju kako se izračunavaju i primenjuju različite mere, kao što je kosinusna distanca za merenje diverziteta.
- Skup podataka: Kao pregledni rad, on ne koristi specifičan skup podataka za eksperimente, već referencira i analizira evaluacione metode koje se primenjuju u drugim radovima na standardnim skupovima podataka poput MovieLens-a.
- Evaluacija rešenja: Rad ne evaluira sistem, već služi kao referenca za to kako evaluirati sistem. Naglašava da je za potpunu evaluaciju potrebno koristiti više metrika koje pokrivaju različite aspekte, a ne samo preciznost.
- Najvažniji rezultati: Pokazano je da su mere poput diverziteta ključne za procenu korisničkog iskustva, jer pružaju uvid u raznolikost preporuka. Takođe, istaknuto je da evaluacija treba da bude višedimenzionalna i da obuhvati različite aspekte kvaliteta.
- Šta nedostaje: Rad je isključivo teorijskog karaktera i ne nudi konkretnu implementaciju. Iako pominje cosine similarity za merenje diverziteta, ne bavi se primenom metrika klasterovanja kao što je Silueta skor u kontekstu evaluacije sistema preporuka.
- Referenca:
https://www.researchgate.net/publication/385736210_Evaluation_Metrics_for_Recommender_Systems_A_Comprehensive_Analysis

Skup podataka

Za realizaciju projekta koristi se javno dostupan TMDb 5000 Movie Dataset, koji se može preuzeti sa platforme Kaggle. Ovaj skup podataka je čest u istraživanjima sistema za preporuku filmova zbog svoje strukture i relevantnih atributa.

- Referenca i izvor:
 - Istraživački rad koji opisuje poreklo i primenu ovog skupa podataka je „The Movie Database (TMDb) API“.
 - Skup podataka je dostupan za preuzimanje na sledećem linku:
<https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata>
- Ciljno obeležje:
 - U ovom projektu, ciljno obeležje nije klasična klasa ili numerička vrednost za predviđanje (kao u klasifikaciji ili regresiji). Umesto toga, cilj je kreiranje vektorskih reprezentacija (embedding-a) filmova i izračunavanje skora sličnosti. Najviši skor sličnosti služi kao kriterijum za izbor ciljnih filmova za preporuku. Stoga, celokupan set atributa filma služi kao osnova za predviđanje sličnosti, a ne za predviđanje jedne specifične vrednosti.
- Atributi za predviđanje:
 - Skup podataka sadrži brojne attribute koji se kombinuju u jedinstvenu matricu osobina, ključnu za preporuke:
 - Tekstualni atributi:
 - genres: Lista žanrova filma.
 - keywords: Lista ključnih reči.
 - overview: Kratak opis filma.
 - title: Naslov filma.

- Numerički atributi:
 - popularity: Indeks popularnosti filma.
 - vote_average: Prosečna ocena filma.
 - vote_count: Ukupan broj glasova.
 - revenue: Prihod filma.

Metodologija

Planirana metodologija za ovaj projekat zasniva se na razvoju hibridnog sistema za preporuku filmova zasnovanog na sadržaju. Model integriše različite tehnike preprocesiranja podataka i mašinskog učenja kako bi generisao relevantne preporuke. Metodologija se može podeliti u sledeće faze:

1. Preprocesiranje podataka i kreiranje matrice osobina

Prvi korak obuhvata transformaciju sirovih podataka iz skupa u numerički format pogodan za mašinsko učenje. Ovaj proces se sprovodi na sledeći način:

- Tekstualni atributi: Za attribute *genres* i *keywords*, koji se sastoje od lista, primenjuje se *CountVectorizer* kako bi se stvorila matrica učestalosti reči. Za semantički bogate attribute, kao što su *overview* i *title*, koristi se model *Word2Vec* (zasnovan na neuronskoj mreži) za generisanje vektorskih reprezentacija (tzv. *embedding-a*). Ovim se omogućava razumevanje semantičke sličnosti između opisa filmova, što je ključni aspekt napredne obrade prirodnog jezika.
- Numerički atributi: Atributi kao što su *popularity*, *vote_average*, *vote_count* i *revenue* se normalizuju na isti opseg korišćenjem *MinMaxScaler*. Ovo osigurava da svi atributi jednako doprinose konačnoj oceni sličnosti.
- Kombinovana matrica: Na kraju, sve ove reprezentacije – matrice iz *CountVectorizer-a*, *embedding-si* iz *Word2Vec-a* i normalizovani numerički podaci – spajaju se horizontalno u jedinstvenu matricu osobina (*features_matrix*). Ova matrica predstavlja svakog filma kao jedinstveni numerički vektor u visokodimenzionalnom prostoru.

2. Algoritam za preporuku

Algoritam preporuke se zasniva na pronalaženju filmova koji su najbliži unetom naslovu, na osnovu njihove pozicije u kreiranom vektorskom prostoru.

- Dinamički izbor metrike: Sistem je dizajniran da automatski izabere najbolju metriku za izračunavanje sličnosti. Ispituje se performansa kosinusne sličnosti (*cosine_similarity*), Euklidske distance (*euclidean_distances*) i skalarnog proizvoda (*linear_kernel*), a zatim se bira ona koja pruža najveći standardnu devijaciju ocena, čime se obezbeđuje bolja separacija i efikasnije preporuke.
- Generisanje preporuka: Nakon što se odabere najbolja metrika, izračunava se sličnost između vektora unetog filma i svih ostalih filmova u matrici. Filmovi sa najvećim skorom sličnosti se sortiraju i vraćaju kao preporuka.

3. Dodatne funkcionalnosti

- Pretraga i filtriranje: Pored primarnog algoritma za preporuke, sistem omogućava korisnicima da pretražuju filmove po naslovu i filtriraju rezultate na osnovu žanra i jezika.
- Sortiranje: Implementirana je mogućnost sortiranja preporučenih filmova po različitim kriterijumima.
- Keširanje: Sistem koristi mehanizam keširanja preporuka za svaki uneti naslov kako bi se poboljšala efikasnost i skratilo vreme odziva.

Metod evaluacije

Evaluacija sistema za preporuku filmova je ključna za procenu njegove efikasnosti i kvaliteta. U ovom projektu, s obzirom na to da je sistem baziran isključivo na sadržaju i da nema podataka o preferencijama korisnika, evaluacija se ne zasniva na tradicionalnim merama predikcije ocena, već na proceni relevantnosti i raznovrsnosti samih preporuka.

Mere performanse

Evaluacija će se sprovesti korišćenjem sledećih mera, inspirisanih relevantnom literaturom:

- *Silueta skor (Silhouette Score)*: Ova metrika se koristi za procenu kvaliteta klasterovanja. Pošto sistem stvara vektorske reprezentacije filmova, Silueta skor će biti primenjen na finalnu matricu osobina kako bi se izmerilo koliko su dobro definisani "klasteri" sličnih filmova. Visok skor ukazuje na to da su filmovi unutar istog klastera slični, dok su klasteri međusobno jasno razdvojeni, što je idealno za efikasno pronalaženje sličnosti.
- *Diverzitet preporuka (Diversity)*: Ova metrika je ključna za procenu raznovrsnosti preporuka koje sistem generiše. Merenje diverziteta je važno kako bi se izbeglo preporučivanje filmova koji su previše slični unetom naslovu. Diverzitet se može meriti izračunavanjem prosečne kosinusne distance između svih parova filmova unutar liste preporuka. Veća distanca ukazuje na veću raznolikost.
- *Kvalitativna analiza*: Pored numeričkih metrika, biće sprovedena i kvalitativna analiza. To podrazumeva vizuelnu inspekciju i interpretaciju rezultata, tj. ručnu proveru da li su preporučeni filmovi zaista relevantni u odnosu na ulazni naslov, uzimajući u obzir žanr, ključne reči i opise.

Postupak evaluacije (eksperiment)

Kako se projekat ne bazira na korisničkim ocenama, klasična podela na trening i test skup nije primenljiva. Evaluacija se sprovodi na sledeći način:

1. Kreiranje matrice osobina: Kao što je definisano u metodologiji, svi atributi (tekstualni i numerički) se preprocesiraju i kombinuju u jedinstvenu matricu osobina za sve filmove u skupu podataka.
2. Evaluacija kvaliteta vektora: Na finalnoj matrici osobina izračunava se Silueta skor kako bi se procenio kvalitet kreiranih vektorskih reprezentacija. To će potvrditi da li su slični filmovi zaista grupisani blizu u vektorskom prostoru.
3. Generisanje i analiza preporuka:
 - Za odabrani skup od 10-20 popularnih filmova, sistem će generisati liste od po 10 preporuka.

- Za svaku listu preporuka, biće izračunata metrika diverziteta.
- Takođe, biće sprovedena kvalitativna analiza, gde će se ručno oceniti relevantnost preporučenih filmova.

Softver

Projekat je zasnovan na primeni više softverskih komponenti i biblioteka, koje omogućavaju efikasnu obradu podataka i izgradnju robustnog sistema. Sva rešenja su open-source i široko prihvaćena u oblasti mašinskog učenja i razvoja veb-aplikacija.

- Backend: Aplikacija je razvijena u *Python*-u (verzija 3.9+) koristeći *Flask* framework. *Flask* služi za kreiranje *RESTful API*-ja koji obrađuje zahteve sa frontenda, pokreće algoritam za preporuke i vraća rezultate.
- Frontend: Za izradu korisničkog interfejsa planira se korišćenje *Angular*-a (verzija 13+). *Angular* omogućava razvoj dinamičkog i interaktivnog frontenda koji komunicira sa backend-om putem API-ja.
- Biblioteke za obradu podataka i mašinsko učenje:
 - *Pandas* i *NumPy* su osnovne biblioteke koje se koriste za manipulaciju i analizu podataka. *Pandas* se koristi za učitavanje i obradu skupa podataka o filmovima, dok se *NumPy* koristi za numeričke operacije i rad sa matricama.
 - *Scikit-learn* se koristi za preprocesiranje podataka (*MinMaxScaler* i *CountVectorizer*) i za izračunavanje sličnosti između filmova (*cosine_similarity*, *euclidean_distances*).
 - *Gensim* je ključna biblioteka za obradu prirodnog jezika, a koristi se za implementaciju *Word2Vec* modela. Ovaj model generiše vektorske reprezentacije za opise i naslove filmova, što je centralni deo metodologije.

Sve navedene biblioteke su javno dostupne i mogu se instalirati putem pip paketa menadžera. Korišćenje ovih etabliranih alata omogućava fokus na sam algoritam preporuke, umesto na implementaciju osnovnih funkcionalnosti.

Moguća unapređenja

1. Poboljšanje algoritma za preporuke
 - Integracija naprednijih NLP modela: Umesto *Word2Vec* modela, mogu se koristiti novije i moćnije metode poput BERT ili Sentence-BERT modela, koji bolje razumeju kontekst rečenica i odnose među pojmovima, čime bi se poboljšala semantička sličnost između filmova.
 - Uvođenje hibridnog pristupa: Trenutni sistem je isključivo zasnovan na analizi sadržaja. Dodavanje elemenata kolaborativnog filtriranja (npr. korišćenjem latentnih faktora iz korisničkih ocena) omogućilo bi kreiranje hibridnog modela koji kombinuje prednosti oba pristupa.
 - Personalizacija preporuka: Implementacija korisničkih profila koji beleže istoriju pretraga ili klikova omogućila bi sistemu da preporuke prilagođava pojedinačnim interesovanjima korisnika.

2. Unapređenje evaluacije

- Dodatne metrike: Pored Silueta skora i diverziteta, mogu se uvesti i mere poput NDCG (Normalized Discounted Cumulative Gain), MAP (Mean Average Precision) ili Hit Rate, koje daju preciznije uvide u kvalitet i relevantnost preporuka.
- A/B testiranje: Kreiranje eksperimentalnog okruženja za poređenje različitih verzija algoritma na osnovu realnih korisničkih interakcija.

3. Optimizacija frontenda i korisničkog iskustva

- Lazy loading slika i drugih medija, uz prikaz privremenih elemenata dok se resursi ne učitaju, značajno bi smanjio početno vreme učitavanja i poboljšao performanse aplikacije.

Spremna sam da razmotrim dodatna proširenja i funkcionalnosti koja bi unapredila sistem. Cilj je da projekat u potpunosti odražava obim i kompleksnost diplomskog rada. Svaka sugestija ili ideja za poboljšanje doprineće kvalitetu i sveobuhvatnosti rešenja.